



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS JARDINS DE ANITA
CURSO DE TECNOLOGIA EM CIÊNCIA DE DADOS
APRENDIZADO PROFUNDO
DR. JÚLIO CÉSAR SANTOS DOS ANJOS

PEDRO COELHO SAMPAIO FILHO - 517578
LARISSA VITÓRIA VASCONCELOS SOUSA - 519221
RUAN RODRIGUES SOUSA - 517453
MATEUS SILVA MATOS - 517459

AVALIAÇÃO 2 - IDENTIFICAÇÃO DE TIPOS DE FLORES

ITAPAJÉ, CE
2024

INTRODUÇÃO

Neste projeto, o objetivo é desenvolver um modelo de aprendizado profundo para identificar os tipos de flores da cidade de Itapajé, utilizando técnicas de *Transfer Learning*. Para isso, será necessário coletar e curar um *dataset* local, aplicando técnicas de pré-processamento de dados e balanceamento, além de avaliar otimizadores e monitorar o desempenho do modelo em termos de acurácia e *loss*.

OBJETIVO

O objetivo principal do projeto é criar um modelo que consiga classificar corretamente as flores encontradas em Itapajé, utilizando um modelo pré-treinado como base, e realizar ajustes com base nos dados coletados localmente. Isso permitirá uma aplicação prática das técnicas de aprendizado profundo estudadas em aula.

METODOLOGIA

Coleta de Dados

- Foram tiradas fotos das flores da cidade de Itapajé utilizando celulares;

Figura 1 - Amostra de flores capturadas em Itapajé-CE



- Através de um processo de validação manual para selecionar as melhores imagens para treinamento, foram selecionadas 369 imagens de 15 espécies de flores. Essa validação incluiu retirada de imagens desfocadas, correção de brilho e redimensionamento para focar a imagem da flor;
- Em seguida, as imagens foram “labeladas” com auxílio da API *PlantNet*, um aplicativo que ajuda a identificar plantas através de fotos.

Curagem e Pré-processamento de Dados

- Técnicas de balanceamento de classes foram aplicadas para evitar o viés no treinamento do modelo;
- Foram removidos ruídos nas imagens, e as dimensões foram ajustadas de maneira padronizada (*resize*) para garantir consistência no modelo;
- Utilizou-se *Data Augmentation* para aumentar a diversidade do *dataset*, aplicando rotações, espelhamento e ajustes de brilho e contraste.

Transfer Learning

- Foi utilizado o modelo pré-treinado *VGG16*, uma arquitetura de rede neural convolucional amplamente utilizada para classificação de imagens;
- A estratégia de *Transfer Learning* permitiu utilizar as características extraídas das camadas convolucionais treinadas em grandes *datasets* de imagens (como o *ImageNet*) e adaptá-las para o nosso *dataset* local de flores.

Otimização

- Foram testados diferentes otimizadores, como Adam e SGD, variando a *learning rate* para encontrar o melhor desempenho em termos de acurácia e tempo de treinamento;
- Após o treinamento inicial, realizamos *fine-tuning* nas últimas camadas da rede com uma *learning rate* menor para refinar o modelo.

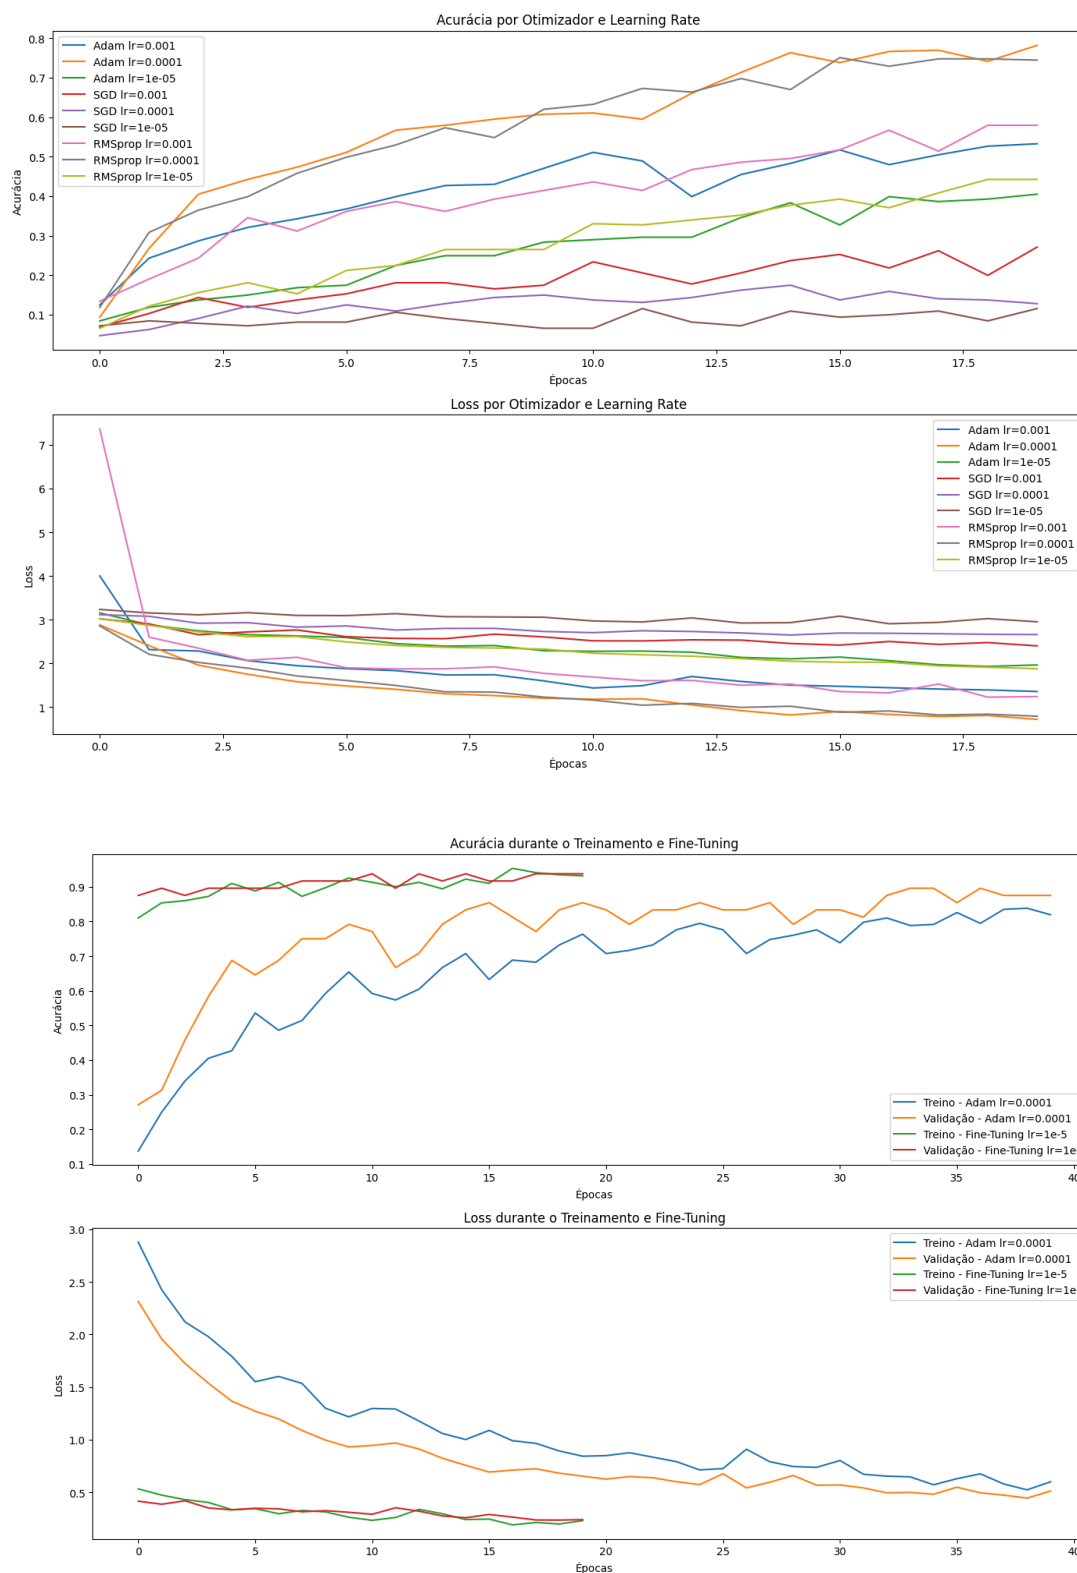
Avaliação do Modelo

- As métricas de acurácia e loss foram monitoradas durante o treinamento para identificar possíveis sinais de overfitting e ajustes necessários;
- O desempenho foi avaliado em um conjunto de validação, e gráficos comparando a acurácia e a loss ao longo das épocas de treinamento foram gerados para auxiliar na análise final.

RESULTADOS


Curvas de Acurácia e Loss

As curvas de acurácia e *loss* apresentaram uma melhora constante nas primeiras épocas, estabilizando nas épocas finais. Observamos que, após o uso do *Data Augmentation* e *fine-tuning*, a generalização do modelo foi significativamente aprimorada.



Comparação de Otimizadores

O otimizador Adam com *learning rate* reduzida se destacou no treinamento, apresentando uma melhor convergência e acurácia em comparação com o SGD. O modelo final, utilizando o Adam com *fine-tuning*, alcançou uma acurácia de validação de 98,88%.



CONCLUSÃO

O modelo desenvolvido demonstrou ser altamente eficaz na classificação das espécies de flores de Itapajé, aproveitando técnicas de *Transfer Learning* para reduzir o tempo de treinamento e aumentar a precisão. A utilização de *Data Augmentation* e ajuste fino das camadas finais do modelo contribuiu para o aumento da capacidade de generalização. Para trabalhos futuros, sugerimos a coleta de um *dataset* maior e a experimentação com outras arquiteturas de rede neural, como *ResNet*.

LINKS DATASET E CÓDIGO

Dataset - [📁 Deep_Learning_Flowers](#)

Código - [🔗 Deep_Learning_flowers.ipynb](#)